方思童 Sitong Fang

sitongfang1@gmail.com · sitongfang.com · Lavezlyn

面向物理智能的基础模型训练。研究兴趣：世界模型与可信多模态人工智能。

教育背景

北京大学 学士，2023 – 2027（预计）
元培学院，人工智能专业

- **个人荣誉**：商汤奖学金；元培青年学者；博雅奖学金；北京市自然科学基金本科生“启研”计划；新生奖学金（一等）
- **技术技能**：Python, PyTorch, vLLM, DeepSpeed, Ray, CUDA, C/C++, LaTeX

学术成果

When Slower Isn't Truer: Inverse Scaling Law of Truthfulness in Multimodal Reasoning **ACL 2026**
Sitong Fang, Wenjing Cao, Jiahao Li, Xuyao Wang, Chi-Min Chan, Sirui Han, Juntao Dai, Yike Guo, Yaodong Yang, Jiaming Ji

- 发现逆缩放定律：更慢的推理模型在多模态场景中反而更不真实。
- 提出 **TruthfulVQA**，首个多模态真实性评测基准（5,000+ 图像），以及 **TruthfulJudge** 人机协同评测框架。

Debate with Images: Detecting Deceptive Behaviors in Multimodal Large Language Models **ICML 2026**
Sitong Fang, Shiyi Hou, Kaile Wang, Boyuan Chen, Donghai Hong, Jiayi Zhou, Juntao Dai, Yaodong Yang, Jiaming Ji

- 提出 **MM-DeceptionBench**，首个多模态大模型欺骗行为评测基准。
- 提出 **Debate with Images**，基于视觉证据的多智能体辩论框架，显著提升欺骗检测准确率。

AI Alignment Can Build Moral Autonomy **NeurIPS 2026**
Kaile Wang*, Hantao Lou*, Tianyi Qiu*, Sebastian Sunday-Grève, Sitong Fang, Xinxiong Wu, Jiaming Ji, Yaodong Yang
* 共同贡献

- 探讨以道德自主性为对齐目标，强调反思性认可、明确的原则与实践智慧。

A Blind Spot in Alignment: Quantifying Biosecurity Risks in Large Language Models **COLM 2026**
Shu Quan, Tianfang Hao, Sitong Fang, He Geng, Jiayi Zhou, Boyuan Chen, Kaile Wang, Donghai Hong, Juntao Dai, Yaodong Yang, Jiaming Ji

- 提出 **SPIKE-Bench**，结合功能性有害率（Functional Harmfulness Rate）评估语言模型的生物安全风险。

AI Deception: Risks, Dynamics, and Controls
Boyuan Chen*, Sitong Fang*, Jiaming Ji*, ..., Yaodong Yang†, Tiejun Huang†, Ya-Qin Zhang†, HongJiang Zhang†, Andrew Yao†
* 共同贡献 † 通讯作者

- 首篇 AI 欺骗系统性国际报告（50+ 位作者），图灵奖得主姚期智院士任通讯作者。
- 基于信号理论定义 AI 欺骗，分析欺骗循环机制，提出缓解策略。

Mitigating Deceptive Alignment via Self-Monitoring **Preprint**
Jiaming Ji*, Wenqi Chen*, Kaile Wang, Donghai Hong, Sitong Fang, Boyuan Chen, Jiayi Zhou, Juntao Dai, Sirui Han, Yike Guo, Yaodong Yang
* 共同贡献

- 提出 **CoT Monitor+**，在思维链推理中嵌入自我监控机制，检测并抑制欺骗性对齐。

科研经历

逆矩阵科技（Physis AI） 2026.02 – 至今
算法合伙人

- 训练能够学习物理动态、预测行动后果的基础模型。

北京大学对齐小组（PKU-Alignment） 2024.12 – 2026.01
研究员 · 导师：杨耀东老师

- 主导开发 **TruthfulVQA**，首个多模态真实性评测基准（ACL 2026）。
- 主导开发 **Debate with Images**（ICML 2026），基于视觉的多智能体辩论欺骗检测框架，以及 **MM-DeceptionBench**，首个多模态欺骗评测基准。
- 共同一作 **AI Deception Survey**，图灵奖得主姚期智院士任通讯作者。
- 多模态后训练框架 **Align-Anything** 和多模态评测框架 **Eval-Anything** 的核心贡献者与维护者。

HKGAI 研发中心 / 香港科技大学 2024.12 – 2025.03
研究员

- 参与面向香港本地需求的多语言大模型 **HKGAI-V1** 的训练，并获香港生成式人工智能研发中心出具的贡献确认函。

荣誉奖项

2026 商汤奖学金 全国仅 *30* 人
2025 元培青年学者 每年 *10* 人
2025 北京市自然科学基金本科生“启研”计划 北大 *2023* 级人工智能专业唯一获资助者
2024 北京大学博雅奖学金
2024 北京大学招商证券奖学金
2024 北京大学学习优秀奖
2024 北京大学社会工作奖
2023 北京大学新生奖学金（一等）
2023 福建省高考物理类第一名