

方思童 Sitong Fang

✉ sitongfang1@gmail.com · 🌐 sitongfang.com · 📄 Lavezlyn

研究兴趣：可信多模态人工智能、世界模型、人工智能对齐与安全

教育背景

北京大学
元培学院，人工智能专业

学士，2023–2027（预计）

- 个人荣誉：商汤奖学金；元培青年学者；博雅奖学金；宋庆龄未来助学金；北京市自然科学基金本科生“启研”计划；新生奖学金（一等）
- 技术技能：Python, PyTorch, vLLM, DeepSpeed, Ray, CUDA, C/C++, L^AT_EX

学术成果

When Slower Isn't Truer: Inverse Scaling Law of Truthfulness in Multimodal Reasoning **ACL 2026** 

Sitong Fang, Wenjing Cao, Jiahao Li, Xuyao Wang, Chi-Min Chan, Sirui Han, Juntao Dai, Yike Guo, Yaodong Yang, Jiaming Ji

- 发现逆缩放定律：更慢的推理模型在多模态场景中反而更不真实。
- 提出 **TruthfulVQA**，首个多模态真实性评测基准（5,000+ 图像），以及 **TruthfulJudge** 人机协同评测框架。

Debate with Images: Detecting Deceptive Behaviors in Multimodal LLMs **ICML 2026** 

Sitong Fang, Shiyi Hou, Kaile Wang, Boyuan Chen, Donghai Hong, Jiayi Zhou, Juntao Dai, Yaodong Yang, Jiaming Ji

- 提出 **MM-DeceptionBench**，首个多模态大模型欺骗行为评测基准。
- 提出 **Debate with Images**，基于视觉证据的多智能体辩论框架，显著提升欺骗检测准确率。

AI Deception: Risks, Dynamics, and Controls **在审** 

Boyuan Chen*, Sitong Fang*, Jiaming Ji*, ..., Yaodong Yang†, Tiejun Huang†, Ya-Qin Zhang†, HongJiang Zhang†, Andrew Yao†

- 首篇 AI 欺骗系统性国际报告（50+ 位作者），图灵奖得主姚期智院士任通讯作者。投稿至 ACM Computing Surveys。
- 基于信号理论定义 AI 欺骗，分析欺骗循环机制，提出缓解策略。

科研经历

逆矩阵科技 (Physis AI)
研究员

2026.02 – 至今

- 世界模型创业公司，致力于构建真正理解物理规律的世界基础模型。高瓴创投、燕缘创投联合投资。

北京大学对齐小组 (PKU-Alignment)

2024.12 – 至今

研究实习生 · 导师：杨耀东助理教授

- 主导开发 **TruthfulVQA**，首个多模态真实性评测基准（ACL 2026）。
- 主导开发 **Debate with Images** (ICML 2026)，基于视觉的多智能体辩论欺骗检测框架，以及 **MM-DeceptionBench**，首个多模态欺骗评测基准。
- 共同一作 **AI Deception Survey**，图灵奖得主姚期智院士任通讯作者。
- Align-Anything** (GitHub 4,600+ 星) 核心贡献者，全模态对齐框架。
- Eval-Anything** 核心贡献者，全模态安全评测框架。

HKGAI 研发中心 / 香港科技大学

2024.12 – 2025.03

研究实习生

- 参与 **HKGAI-V1** 开发，香港政府首个基于 DeepSeek 的本地化微调生成式 AI 模型，支持粤语、普通话和英语，具备本地化安全对齐能力。

荣誉奖项

2026	商汤奖学金	全国仅 30 人
2025	元培青年学者	仅 10 人
2025	北京市自然科学基金本科生” 启研” 计划	年级唯一
2025	宋庆龄未来助学金	全校仅 10 人
2024	北京大学博雅奖学金	
2024	北京大学招商证券奖学金	
2024	北京大学学习优秀奖	
2024	北京大学社会工作奖	
2023	北京大学新生奖学金（一等）	
2023	福建省高考理科第一名	